

STATE OF DATA BRASIL

O Mercado Brasileiro de Dados, Analytics e IA (2023–2025/26)

Diagnóstico executivo para apoiar a estratégia de contratação, capacitação e investimento em tecnologia de uma Instituição Financeira de grande porte

GRUPO 7:

Camila de Oliveira - RM 371409

Lucas Zucoloto Soares Valbusa - RM 373425

Luysa Brito de Paiva Lima - RM 373813

Tatiana Regina da Silva - RM 373518

Vanessa Gomes Cardoso - RM 373426

Consultoria de Dados & Analytics | Pipeline AWS: S3 → Glue → Bronze/Silver → Athena (Gold via CTAS)

Por que este diagnóstico agora?

- A instituição financeira quer expandir sua área de Dados, Analytics e IA e precisa de evidências de mercado — não de suposições — para embasar contratação, capacitação e investimento.
- Usamos 3 ciclos da pesquisa State of Data Brasil (Data Hackers + Bain): 2023, 2024 e 2025/2026 juntos, 14.002 respondentes.
- O desafio de engenharia: as 3 bases não compartilham o mesmo schema, por isso foi necessário harmonizar aproximadamente 35 campos equivalentes entre os ciclos, com auditoria extensa de qualidade antes de qualquer análise comparativa.
- **Resultado:** uma base analítica única no AWS Glue Data Catalog, consultável via Amazon Athena, capaz de responder às perguntas de negócio que orientam este material.

14.002

respondentes
(2023–2025/26)

+27%

crescimento no salário
médio nominal

98,2%

já usam IA Generativa no
trabalho (2025/26)

Pipeline de dados: do CSV bruto ao insight executivo

1. Ingestão

3 CSVs do Kaggle enviados ao S3 via boto3 e versionados na camada Bronze via Glue Job com de forma que se auto-cataloga na escrita.

2. Harmonização

Auditoria de qualidade (nulos, duplicatas, separador diferente em 2023) + mapeamento De/Para de ~35 campos entre os 3 ciclos.

3. Camada Silver

Tabela única tb_state_data_silver_v2 em Parquet, particionada por ano_pesquisa, catalogada via saveAsTable.

4. Gold via Athena

O Athena materializa as 7 tabelas analíticas direto da Silver via CTAS (CREATE TABLE AS SELECT).

5. DataViz

Export CSV via Athena + ferramenta de BI geram os painéis e a narrativa executiva deste material.


Ferramentas utilizadas: Amazon S3 · AWS Glue (Jobs + Notebooks + Catalog) · Apache Spark/PySpark · Amazon Athena · BI para DataViz

A camada Gold foi materializada diretamente pelo Amazon Athena, via CTAS, a partir da camada Silver, dessa forma conseguimos deixar com menos um componente na pipeline mantendo a mesma lógica de negócio.

ARQUITETURA AWS

Arquitetura AWS — Pipeline State of Data Brasil (fluxograma padrão)

2023 + 2024 + 2025/2026 | Sem Crawlers — cada camada se auto-cataloga na escrita | Gold materializada via Athena (CTAS)




Como está estruturado o mercado brasileiro de Dados?

Estrutura do Mercado

Como vem se apresentando a evolução da distribuição de profissionais no período avaliado.

	2023	2024	2025
Analista de Dados/Data Analyst e DBA	24,0%	25,1%	24,0%
Cientista de Dados/Data Scientist	17,8%	18,0%	16,9%
Engenheiro de Dados/Arquiteto de Dados/Data Engineer	17,7%	16,0%	16,1%
Analista de BI/BI Analyst	13,1%	10,4%	8,6%
Outra Opção	9,0%	8,4%	10,3%
Analista de Negócios/Business Analyst	5,1%	4,8%	5,6%
Analytics Engineer	3,6%	6,0%	5,4%
Desenvolvedor/ Engenheiro de Software/ Analista de Sistemas	2,7%	3,2%	4,2%
Engenheiro de Machine Learning/ML Engineer/AI Engineer	1,9%	2,7%	4,2%
Analista de Suporte/Analista Técnico	1,9%	2,0%	2,2%
Data Product Manager/ Product Manager (PM/APM/DPM/GPM/PO)	2,1%	2,1%	1,3%
Arquiteto de Dados/Data Architect		1,3%	1,1%
Analista de Inteligência de Mercado/Market Intelligence	1,0%		

Profissionais x Região



Mercado ainda muito concentrado no Sudeste (61-64%), mas com leve avanço de Nordeste e Centro-Oeste entre 2023 e 2025, gerando oportunidade para squads distribuídos fora do eixo tradicional.

Leitura dos dados

- Analista de Dados/DBA (24,0%), Cientista de Dados (16,9%) e Engenheiro de Dados (16,1%) concentram quase 60% do mercado em 2025.
- BI (8,6%) e Analytics Engineer (5,4%) seguem relevantes; cargos de liderança/produto (Data PM, Arquiteto) ainda são minoria.
- 'Outra Opção' cresce de 9,0% para 10,3%, o que mostra um sinal de que o mercado está criando funções híbridas que as categorias tradicionais não capturam bem.
- Recomendação:** dimensionar o time-alvo priorizando Analista + Cientista + Engenheiro de Dados como núcleo de contratação.

Quais perfis profissionais são mais valorizados (remuneração)?


Valorização x Perfis									
Faixa Salarial	2023			2024			2025		
	Júnior	Pleno	Sênior	Júnior	Pleno	Sênior	Júnior	Pleno	Sênior
Acima de R\$ 40.001/mês		0,1%	0,7%	0,0%		0,8%		0,1%	1,0%
de R\$ 1.001/mês a R\$ 2.000/mês	5,0%	0,4%	0,0%	3,7%	0,2%		4,0%	0,4%	0,1%
de R\$ 2.001/mês a R\$ 3.000/mês	5,5%	1,3%	0,3%	4,9%	0,8%	0,2%	3,9%	0,8%	0,2%
de R\$ 3.001/mês a R\$ 4.000/mês	5,1%	3,3%	0,3%	4,1%	2,3%	0,2%	3,5%	2,0%	0,4%
de R\$ 4.001/mês a R\$ 6.000/mês	7,6%	9,2%	1,4%	5,7%	8,1%	1,0%	4,9%	6,5%	1,4%
de R\$ 6.001/mês a R\$ 8.000/mês	2,0%	9,6%	3,4%	2,3%	10,2%	3,2%	1,9%	7,8%	3,2%
de R\$ 8.001/mês a R\$ 12.000/mês	1,1%	9,1%	13,1%	1,0%	10,9%	13,2%	1,5%	10,1%	11,1%
de R\$ 12.001/mês a R\$ 16.000/mês	0,1%	2,1%	10,2%	0,1%	2,1%	11,8%	0,3%	2,5%	8,1%
de R\$ 16.001/mês a R\$ 20.000/mês	0,1%	0,5%	3,6%	0,1%	0,6%	5,9%		0,3%	4,7%
de R\$ 20.001/mês a R\$ 25.000/mês		0,2%	1,9%	0,0%	0,3%	2,1%	0,0%	0,2%	1,9%
de R\$ 25.001/mês a R\$ 30.000/mês		0,2%	1,0%	0,1%	0,1%	1,3%		0,2%	1,2%
de R\$ 30.001/mês a R\$ 40.000/mês		0,1%	0,9%	0,0%	0,2%	1,3%		0,2%	1,0%
Menos de R\$ 1.000/mês	0,6%	0,1%		0,7%	0,1%	0,0%	0,7%		

Leitura do mapa de calor: quanto mais escura a célula, maior a concentração de respondentes naquela combinação de faixa salarial x senioridade.

Leitura dos dados

- Sênior concentra a maior densidade na faixa R\$ 8-12 mil/mês nos 3 ciclos com teto de carreira estável.
- Pleno migra visivelmente: em 2023 a moda estava em R\$ 6-8 mil; em 2025 já está em R\$ 8-12 mil, a mesma faixa do Sênior.
- Compressão salarial
Pleno↔Sênior é sinal real de mercado, não possuindo ruído e repetindo nos 3 anos.
- Recomendação:** revisar bandas de Pleno para manter diferenciação clara e evitar fricção de retenção.

Qual o cenário de diversidade de gênero nas carreiras de dados?



Participação feminina cai de forma sustentada nos 3 ciclos: 24,4% (2023) → 23,5% (2024) → 22,0% (2025) sendo uma tendência estrutural, não oscilação pontual.

Leitura dos dados

- Mulheres estão ainda mais concentradas no Sudeste (63,2%) do que os homens (59,7%), sendo assim, a distribuição geográfica de quem se identifica como mulher na área é menos diversificada.
- Homens têm participação relativamente maior em Nordeste (10,9% vs 10,2%) e Centro-Oeste (6,8% vs 5,4%) do que mulheres.
- O grupo 'Outro' está fortemente concentrado no Sudeste (75,0%), contudo a amostra é pequena, exigindo leitura com cautela.
- O mercado de dados segue predominantemente masculino (~78% em 2025), acima da média de outras áreas de tecnologia.
- Recomendação:** metas de diversidade no funil de contratação e trilhas de desenvolvimento para grupos sub-representados, a tendência não irá se reverter sozinha, e é ainda mais aguda fora do Sudeste.

Quais tecnologias apresentam maior adoção entre os profissionais?

Tecnologias Mais Utilizadas

Banco de Dados				
Ranking	Tecnologia	2023	2024	2025
1	PostgreS.. SQL Server	32,08	31,39	36,80
2	Databricks PostgreS.. SQL Server	28,31	31,11	33,51
3	Databricks Google Bi.. SQL Server	26,06	29,33	32,89
4	Google Bi.. MySQL S3	24,58	26,23	28,83
5	Databricks MySQL S3	21,37	23,64	28,54
6	Google Bi.. MySQL S3	20,92	23,19	27,02
7	Oracle	18,19	17,93	19,57
8	Amazon A..	11,96	14,05	15,23
9	MongoDB	11,35	11,46	14,80
10	Amazon R.. SQLite	10,98	10,15	12,32

Cloud

Tecnologia	2023	2024	2025
AWS	43,48	32,00	31,74
Azure	26,99	15,70	14,70
clickhouse		0,03	
Cloud com Databri..		0,03	
Cloud própria	0,05		0,10
Databricks	0,08	0,20	0,24
GCP	27,84	19,43	20,57
IBM Cloud	0,08		
Nao consigo escol..	0,03		
Não tenho conheci..	0,03		
On-premises			0,05
Oracle Cloud	0,13	0,03	0,05
Qlik		0,03	
Sem preferência / ..	0,90	32,53	32,51
Snowflake			0,05
Teradata Vantage		0,03	

Ferramenta de BI


Tecnologia	2023	2024	2025
Microsoft Power BI	57,10	55,18	59,00
Tableau	18,90	18,99	13,63
Looker Studio (antigo Google Data Studio)	17,31	16,67	15,58
Looker	11,66	12,88	12,78
Não utilizo nenhuma ferramenta de BI no tr..	10,84	9,76	11,35
Fazemos todas as análises utilizando ap..	10,37	10,62	10,31
Metabase	8,59	8,79	8,41
Grafana	7,32	8,02	8,69
Outra opção	4,83	9,40	7,36
Qlik View/Qlik Sense	5,14	4,92	
Amazon QuickSight			6,79

Programação

Tecnologia	2023	2024	2025
Python	88,0	88,8	92,0
R	6,1	5,4	
SQL			84,2
R			14,0
SQL	2,0	2,1	
Scala	1,4	1,1	3,3
C/C++/C#			2,3
Rust	0,8	0,7	
C/C++/C#		0,6	
Julia	0,6		
Rust			1,7
C/C++/C#	0,5		
Go		0,3	
Julia			0,9
DAX			0,7
DAX/M	0,2		
Julia		0,2	
Java	0,1		
PySpark			0,6
SAS		0,1	
Go	0,1		
PySpark		0,1	
Spark			0,3

- Python domina com folga (88-92% de preferência nos 3 ciclos) sendo uma base técnica não-negociável para contratação.
- PostgreSQL, SQL Server e Databricks lideram bancos de dados; AWS lidera cloud, mas 32,5% não têm preferência definida em 2025.
- Microsoft Power BI é a ferramenta de BI dominante (59,0% em 2025), à frente de Tableau e Looker Studio.
- **Recomendação:** Python + SQL como requisito técnico-base em praticamente qualquer contratação de dados; Power BI como padrão de BI corporativo.


Qual o índice de adoção de IA Generativa e seu impacto?



Leitura dos dados

- Adoção pessoal de IA Generativa no trabalho salta de 81,0% (2023) para 98,2% (2025) sendo praticamente universal entre os profissionais de dados.
- Já a fatia de empresas com IA como 'Alta prioridade' + 'Principal prioridade' cresce de 36% para 60% no mesmo período, mesmo sendo mais lenta que a adoção pessoal.
- Há uma lacuna real entre adoção pessoal (quase universal) e priorização institucional (ainda minoritária, mesmo crescendo) podendo destacar que os profissionais estão à frente das empresas nesse tema.
- 'Não é prioridade' cai de 28,8% (2023) para 11,3% (2025) indicando que o ceticismo institucional está diminuindo rápido, mesmo que a formalização ainda não tenha alcançado o uso individual.
- **Recomendação:** formalizar a estratégia e a governança de IA Generativa agora, dessa forma o uso informal e descentralizado pelos próprios profissionais já é maioria absoluta e cresce mais rápido que a supervisão institucional.

Existem diferenças relevantes entre regiões, senioridades ou modelos de trabalho?



Leitura dos dados

- ATENÇÃO:** o gráfico 'Modelo x Região' mostra o modelo IDEAL (preferido), não o modelo atual praticado hoje, isso é confirmado na legenda da própria visualização.
- Sênior é proporcionalmente mais presente no Sul (29,2%) e Sudeste (28,2%) do que no Centro-Oeste (25,1%), concluindo que os grandes centros concentram também a maior senioridade.
- Júnior é mais presente no Sudeste (16,3%) e menos no Norte (22,6%) e Centro-Oeste (20,6%) devido a regiões fora do eixo principal têm perfil etário/carreira de júnior relativo.
- No modelo IDEAL por região, 100% remoto é maioria absoluta em quase todas as regiões (38-47%) sendo inclusive onde o modelo atual já é mais presencial.
- Sudeste é a região com maior preferência por híbrido flexível como ideal (43,8%), bem acima das demais, isso é um sinal de que o mercado mais maduro tolera menos o remoto puro.
- Recomendação:** política de trabalho não deveria ser única para todo o Brasil, a preferência regional por modelo varia mais do que a política corporativa média costuma reconhecer.

Quais oportunidades e desafios para empresas que querem investir em Dados e IA?

Desafio Banco de Dados

Banco	Centro-oe..	Nordeste	Norte	Sudeste	Sul	Não Ident.
Amazon Athena	0,3%	0,6%	0,5%	0,8%	0,6%	0,3%
Amazon Redshift	0,1%	0,5%		0,5%	0,5%	0,3%
Databricks	7,3%	6,8%	10,8%	9,5%	11,7%	6,4%
Google BigQuery	3,6%	9,2%	5,6%	8,6%	9,6%	6,9%
MongoDB	0,3%	0,1%	1,0%	0,5%	0,4%	0,3%
MySQL	4,3%	4,0%	5,6%	3,5%	3,9%	1,8%
Não inf.	37,4%	38,4%	39,0%	37,8%	30,7%	45,5%
Oracle	4,3%	2,5%	2,1%	1,7%	2,6%	1,8%
PostgreSQL	29,1%	23,9%	23,1%	18,6%	25,3%	20,2%
S3	2,2%	2,5%	1,0%	3,4%	2,3%	2,8%
SQL Server	10,3%	11,0%	11,3%	14,7%	12,1%	13,6%
SQLite	0,8%	0,5%		0,3%	0,4%	0,3%

Faixa Salarial	Centro-oe..	Nordeste	Norte	Sudeste	Sul	Não Ident.
de R\$ 2.001/mês a R\$ 3.000/mês	6,0%	6,4%	7,2%	4,3%	4,9%	0,8%
de R\$ 3.001/mês a R\$ 4.000/mês	5,5%	6,6%	8,7%	5,0%	7,4%	1,3%
de R\$ 4.001/mês a R\$ 6.000/mês	13,7%	13,4%	9,7%	11,1%	15,1%	3,3%
de R\$ 6.001/mês a R\$ 8.000/mês	12,1%	11,4%	12,3%	11,6%	13,7%	6,9%
de R\$ 8.001/mês a R\$ 12.000/mês	18,2%	17,4%	17,9%	21,0%	21,1%	10,7%
de R\$ 12.001/mês a R\$ 16.000/mês	11,1%	11,4%	7,2%	13,9%	13,6%	10,5%

Adoção IA	Centro-oe..	Nordeste	Norte	Sudeste	Sul	Não Ident.
Não inf.	32,3%	33,7%	32,8%	33,1%	26,6%	42,5%
Não utiliza IA	4,9%	7,2%	6,7%	7,4%	8,7%	3,8%
Utiliza IA	62,8%	59,1%	60,5%	59,5%	64,7%	53,7%

Leitura dos dados

- Adoção de IA é forte em todas as regiões (53-65% 'Utiliza IA'), sem grande diferença regional, indicando que a barreira não é geográfica.
- Faixas salariais mais altas (R\$ 8-12 mil) concentram-se mais em Sudeste e Sul (~21%) que nas demais regiões.
- Recomendação:** investir em IA e capacitação técnica funciona em qualquer região devido ao fato de que a maior barreira é a falta de padronização de resposta/dado, não a adoção em si.

Tabelas de calor mostram a distribuição percentual de cada resposta por região — quanto mais escura a célula, maior a concentração.

Recomendações estratégicas

Contratação

Priorizar Analista, Cientista e Engenheiro de Dados como núcleo; Python + SQL como requisito-base.

Remuneração

Revisar bandas de Pleno — a compressão frente a Sênior é real e pode gerar fricção de retenção.

Diversidade

Metas ativas de diversidade de gênero, com atenção especial a regiões fora do Sudeste, onde o desequilíbrio é maior.

IA Generativa

Formalizar governança de IA agora — o uso pessoal (98%) já superou de longe a priorização institucional (60%).

Modelo de trabalho

Regionalizar a política de trabalho — a preferência por modelo varia mais entre regiões do que a média corporativa reconhece.

Expansão geográfica

Investir em capacitação e IA funciona em qualquer região — a barreira real é padronização de dado, não adoção.

Obrigado.

Pipeline completo, DDLs do Athena e notebooks originais disponíveis no repositório do projeto para reprodução e aprofundamento.

Link do Github: https://github.com/tatireginas/tech_challenge_fase_3